

Project Handout: “Vinho Verde”

Inteligência Artificial Aplicada

Miguel Correia
<m57609@alunos.uevora.pt>

Horvanda Marreiros
<mailto:m56866@alunos.uevora.pt>

5 de Janeiro de 2023

1 Introdução

Este projeto tem como objetivo desenvolver os modelos de regressão linear (simples e múltipla) e de classificação (classificação de vetor de suporte) para prever o teor do álcool dos vinhos e prever a qualidade do vinho, explorando de forma mais específica os fatores que impactam a qualidade dessas bebidas. Para alcançar esse objetivo, são utilizados conjuntos de dados de vinho tinto e branco, cada um contendo informações detalhadas sobre diversas características químicas e físicas, como acidez, teor de açúcar residual, pH, qualidade, entre outras.

Ao combinar esses conjuntos de dados em uma única fonte de informação, o projeto busca obter uma visão abrangente e integrada, permitindo a análise de como diferentes variáveis influenciam o teor alcoólico dos vinhos. A abordagem se estende para uma análise mais específica, concentrando-se especialmente nos fatores que desempenham um papel crucial na determinação da qualidade dos vinhos.

O projeto abrange a modelagem tanto por meio de regressão linear simples quanto por classificação, proporcionando uma compreensão mais profunda das relações entre as características dos vinhos e o teor do álcool, bem como a qualidade percebida dessas bebidas. Ao considerar distintamente vinhos tintos e brancos, busca-se capturar nuances específicas associadas a cada tipo de vinho.

Com a análise resultante, espera-se obter informações valiosas que possam contribuir para a compreensão dos elementos-chave que impactam a qualidade dos vinhos, proporcionando uma base sólida para tomada de decisões informadas na produção e seleção de vinhos.


2 Resultados

Na definição do modelo de aprendizagem, foram empregados os algoritmos de regressão e classificação.

Para a execução da parte prática usamos o Python, reconhecido como uma das linguagens de programação mais populares e versáteis na atualidade, foi escolhido como o ambiente principal para desenvolvimento. A utilização do Spyder, uma interface gráfica que se assemelha ao Matlab, proporcionou um ambiente interativo, simplificando tarefas como edição de scripts, testes, depuração e visualização gráfica.(MENEZES, 2014) O Spyder oferece suporte à implementação de diversos algoritmos em Java, incluindo árvores de decisão, support vector machines, regras de decisão, entre outros.(CUSTÓDIO, 2017)

Na fase inicial, foi realizada a avaliação da hipótese de regressão linear simples e múltipla. Este processo constituiu um passo crucial para compreender a relação entre as variáveis dependentes e independentes, permitindo uma análise mais aprofundada do conjunto de dados. Este método proporcionou informações valiosas sobre a natureza dos dados e orientou a escolha do modelo mais adequado para os objetivos específicos do projeto:

2.1 Conjunto de dados



OLS Regression Results


Dep. Variable:	alcohol	R-squared:	0.860
Model:	OLS	Adj. R-squared:	0.860
Method:	Least Squares	F-statistic:	1697.
Date:	Sun, 14 Jan 2024	Prob (F-statistic):	0.00
Time:	13:06:52	Log-likelihood:	-1805.6
No. Observations:	3849	AIC:	3635.
Df Residuals:	3837	BIC:	3707.
Df Model:	11		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	659.7825	7.331	89.997	0.000	645.408	674.157
fixed acidity	0.5720	0.013	44.167	0.000	0.547	0.597
volatile acidity	1.5756	0.004	18.867	0.000	1.412	1.739
citric acid	0.5872	0.009	6.579	0.000	0.412	0.762
residual sugar	0.2161	0.004	55.006	0.000	0.209	0.224
chlorides	10.6217	0.784	13.550	0.000	9.085	12.159
free sulfur dioxide	6.039e-05	0.001	0.083	0.934	-0.001	0.001
total sulfur dioxide	-0.0033	0.000	-13.878	0.000	-0.004	-0.003
density	-668.9826	7.544	-88.682	0.000	-683.774	-654.192
pH	2.6680	0.070	38.083	0.000	2.531	2.805
sulphates	1.4670	0.078	18.828	0.000	1.314	1.620
quality	0.1003	0.012	8.343	0.000	0.077	0.124

Omnibus: 469.617 Durbin-Watson: 2.014
Prob(Omnibus): 0.000 Jarque-Bera (JB): 1731.662
Skew: 0.736 Prob(JB): 0.00
Kurtosis: 6.386 Cond. No. 1.84e+05

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.84e+05. This might indicate that there are strong multicollinearity or other numerical problems.

Figura 1 – Conjunto de dados do projeto



	variables	VIF
0	fixed acidity	93.958131
1	volatile acidity	11.519580
2	citric acid	13.717608
3	residual sugar	3.533984
4	chlorides	15.129037
5	free sulfur dioxide	10.382784
6	total sulfur dioxide	16.171141
7	density	946.187662
8	pH	666.539820
9	sulphates	24.288605
10	quality	68.721113

In [251]:

Figura 2 – Variáveis do conjunto de dados

2.2 Algoritmo de Regressão

A escolha de utilizar tanto a regressão linear simples quanto a regressão linear múltipla para prever o teor de álcool fundamenta-se na preferência por modelos paramétricos simples, que proporcionam interpretações diretas dos coeficientes. O coeficiente associado a cada variável independente em ambos os casos reflete a inclinação da reta de regressão, oferecendo uma compreensão clara de como a variável dependente, neste caso, o teor do álcool, sendo particularmente útil quando se busca uma compreensão direta das relações entre as características dos vinhos e seu teor do álcool.

A modelagem por meio de regressão linear simples e múltipla revelou padrões significativos nas relações entre as variáveis explicativas e o teor alcoólico dos vinhos. As análises forneceram uma compreensão clara das influências diretas de diferentes características químicas e físicas no teor alcoólico, contribuindo para a otimização dos processos de produção.

Nas imagens seguintes é apresentado o resultado dos algoritmos de regressão:

```
[ ]: Regressão linear simples
[00]: modelreg = linearRegression()
      modelreg.fit(X_train, y_train)
      print("Intercept: ", modelreg.intercept_)
      print("Coef: ", modelreg.coef_)
      y_pred = modelreg.predict(X_test)
      print("MAE: ", metrics.mean_absolute_error(y_test, y_pred))
      print("MSE: ", metrics.mean_squared_error(y_test, y_pred))
      print("R2_score: ", r2_score(y_test, y_pred))

      MAE: 0.3411445116604072
      MSE: 0.19138772341358368
      R2_score: 0.8637868870141629

[01]: print("Intercept: \n", modelreg.intercept_)
      print("Coefficients: \n", modelreg.coef_)


      Intercept:
      659.782453294132
      Coefficients:
      [ 0.00000000e+00  5.71609953e-01  1.57561538e+00  5.87238345e-01
        2.16115506e-01  1.80216532e+01  6.83902896e-05 -3.38114235e-03
        -6.68982625e-02  2.66800151e+00  1.46698873e+00  1.80298685e-01]
```

Figura 3 – Regressão Linear Simples

```
Multiple Linear Regression
[01]: multireg = linearRegression()
      multireg.fit(X_train, y_train)
      print("Intercept: ", multireg.intercept_)
      print("Coefficients: ", multireg.coef_)

      Intercept:
      25.3123384338881
      Coefficients:
      [ 0.00000000e+00  5.01202110e-01  1.81768810e-01  1.89911850e-02
        9.71223331e-01  1.77578030e-01  9.40000000e-04  1.01478000e-01
        1.84388200e-02  5.86427800e-01  1.09114000e-01  7.70107100e-02]
```

Figura 4 – Regressão Linear Múltipla



	Red	White	Alcohol	Acidity	Ash	Chlorophyll	Fixed Acidity	Free Sulfur	Total Sulfur	Density	pH	Quality
mean	13.20000	13.20000	13.20000	13.20000	13.20000	13.20000	13.20000	13.20000	13.20000	13.20000	13.20000	13.20000
std	1.765000	1.765000	1.765000	1.765000	1.765000	1.765000	1.765000	1.765000	1.765000	1.765000	1.765000	1.765000
min	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000
max	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000
25%	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000
50%	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000
75%	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000
max	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000	17.00000

Figura 5 – Red and White Dataset




Figura 6 – Representação gráfica da Regressão Linear

2.3 Algoritmo de Classificação

O algoritmo Support Vector Classification (SVC) foi empregado com sucesso para classificar a qualidade do vinho. Demonstrando sua eficácia, o SVC é capaz de identificar o hiperplano ótimo que separa distintamente as diferentes categorias de qualidade de vinho, mesmo em situações em que os dados não são linearmente separáveis. A utilização do truque do kernel permite que o SVC opere em um espaço de características transformado, facilitando assim a correta classificação dos vinhos em suas respectivas categorias de qualidade. O SVC demonstrou eficácia na classificação da qualidade dos vinhos, identificando um hiperplano ótimo mesmo em cenários onde os dados não eram linearmente separáveis. A utilização do truque do kernel permitiu operar em um espaço de características transformado, refinando a capacidade de prever a qualidade dos vinhos com precisão.

Nas imagens seguintes é apresentado o resultado do algoritmo de classificação:




Figura 7 – Representação gráfica da categoria type




Figura 8 – Categoria type




Figura 9 – Algoritmo da matriz de confusão




Figura 10 – Matriz de Confusão/Representação do vinho tinto 0 e vinho branco 1

2.4 Previsão da Qualidade

Para prever a qualidade dos vinhos, utilizou-se o método k-Nearest Neighbors (k-NN) e a Regressão Logística, que permitiu estimar a probabilidade de um vinho pertencer a uma categoria específica de qualidade.

A previsão da qualidade dos vinhos por meio do método k-Nearest Neighbors (k-NN) e Regressão Logística trouxe resultados promissores. Esses algoritmos permitiram estimar a probabilidade de um vinho pertencer a uma determinada categoria de qualidade, fornecendo uma ferramenta valiosa para a seleção e produção de vinhos de alta qualidade.

Nas imagens seguintes é apresentado o resultado dos algoritmos:




Figura 11 – Algoritmo K-nn




Figura 12 – Algoritmo K-nn




Figura 13 – Knn-chart




Figura 14 – Representação gráfica da previsão da quantidade dos vinhos

3 Conclusões

O projeto empreendeu uma análise abrangente dos conjuntos de dados de vinho tinto e branco, visando desenvolver modelos preditivos tanto para o teor do álcool quanto para a qualidade dos vinhos. A abordagem empregada envolveu a utilização de técnicas de regressão linear (simples e múltipla) e classificação de vetor de suporte (SVC), proporcionando informações valiosas sobre as características que influenciam essas duas variáveis críticas. Este projeto contribui para o entendimento mais profundo das relações entre características específicas dos vinhos e suas propriedades críticas. Os modelos desenvolvidos foram aplicados para aprimorar processos de produção, seleção de uvas e garantia da qualidade.

Embora os resultados sejam promissores, é importante reconhecer as limitações, como a sensibilidade dos modelos aos dados disponíveis. Futuras pesquisas podem explorar conjuntos de dados mais amplos e incluir técnicas avançadas de aprendizado de máquina para aprimorar ainda mais a precisão das previsões. Em síntese, este projeto proporcionou uma visão holística das características dos vinhos, fornecendo ferramentas valiosas para aprimorar a produção e seleção, promovendo avanços na indústria vinícola e contribuindo para a apreciação e qualidade dessas renomadas bebidas.

Referências

CUSTÓDIO, S. *Modelação Numérica (2016/17) L-MOG, L-EG, MI-EEA DEGGE, FCUL*. 2017.

MENEZES, N. *INTRODUÇÃO À PROGRAMAÇÃO COM PYTHON* Python Software Foundation. Disponível em: <<https://www.python.org/>>. Acesso em: dezembro de 2015. 2014.