

Redes Neurais e Aprendizagem Profunda

Construção de um classificador



Com este trabalho pretende-se ter um primeiro contacto com a biblioteca scikit-learn e com funções para problemas de aprendizagem supervisionada.

Os conjuntos de dados utilizados, *Iris* e *Breast-cancer*, representam dados reais e são usualmente utilizados para demonstrar e testar todo o processo de construção e avaliação de modelos. São considerados frequentemente "toy dataset" já que não colocam especiais desafios do ponto de vista da classificação. Para além destes, o scikit-learn disponibiliza, à partida, outros 5 conjuntos: Boston, Diabetes, Digits, Linnerud e Wine. Pode consultar mais informação em https://scikit-learn.org/stable/datasets/toy_dataset.html

Qualquer um desde 7 conjuntos estão, entre muitos outros e desde há muitos anos, disponíveis em <https://archive.ics.uci.edu/ml/datasets>.

Os exercícios devem ser realizados no Jupyter Notebook (com as respostas a serem mostradas em células distintas). A submissão no moodle deve incluir quer o ficheiro `ipynb` quer um `pdf` gerado que mostre o resultado da execução do código (e resposta às perguntas).

A. Iris

1. Leia a descrição do conjunto disponível num dos links acima referidos.
2. O código em `"iris.py"` permite aplicar o algoritmo KNN ao conjunto de dados *Iris*. Utilize-o no Jupyter notebook criando células que permitam responder às diferentes questões.
 - a. Qual a exatidão do modelo?
 - b. Observe a matriz de confusão e **confirme** o número de exemplos nos conjuntos de treino e teste.
 - c. Quantas flores foram bem classificadas? Quantas flores "setosa" foram classificadas como "versicolor" e quantas foram classificadas como "virginica"?
3. Identifique o que faz **cada uma das chamadas de função** no código.
 - a. Quais os parâmetros por omissão das funções `"train_test_split()"`, `"KNeighborsClassifier()"`?
 - b. O que faz a função `"fit()"`?
 - c. E a função `"predict()"`?
4. Usando sub-conjuntos do conjunto de treino com dimensão a variar entre 5 e o total de exemplos (daquele conjunto) com passo de 5 exemplos, ou seja {5, 10, 15, ... n}.
 - a. Crie modelos e aplique-os ao conjunto de teste. Observe o resultado em termos de desempenho.
 - b. Utilizando a biblioteca `"matplotlib"` faça uma curva do desempenho (exatidão) em função do nº de exemplos do conjunto de treino.

A. Breast-cancer

1. Leia a descrição do conjunto.
2. Usando um Jupyter notebook, aplique o algoritmo KNN ao conjunto de dados Wisconsin Breast Cancer:
 - a. Usando uma divisão treino-teste 80%-20%, calcule o desempenho (exatidão) do KNN sobre os conjuntos de treino e teste com o nº de vizinhos a variar entre 1 e 10.
 - b. Utilizando a biblioteca "`matplotlib`" faça um gráfico do desempenho (exatidão) sobre os dois conjuntos em função do nº de vizinhos.