

Redes Neurais e Aprendizagem Profunda

Treino de modelos



Pretende-se construir um modelo capaz de prever o preço médio da habitação num bairro da Califórnia, a partir de um conjunto de dados (`housing.zip`) com informação sobre população, salário médio e mediana do preço da habitação para cada quarteirão (grupo entre 600 e 3000 pessoas).

Crie um Jupyter notebook com as suas experiências seguindo os pontos seguintes

1. Conhecer o problema
 - a. Qual o tipo de problema de AA que pretendemos tratar?
 - b. Qual a medida de desempenho será adequada?
2. Conhecer os dados
 - a. Obtenha as primeiras linhas do conjunto, a descrição sumária dos dados e um sumário de cada um dos atributos.
 - b. Verifique a distribuição dos valores dos atributos (numéricos) através de histogramas
 - c. Crie conjuntos de treino e teste com 80-20% dos dados. Verifique a proporção de exemplos nos conjuntos completo, treino e teste assumindo 5 categorias do salário médio usando os seguintes valores para construir os intervalos (fechados à esquerda, abertos à direita): 0, 1.5, 3.0, 4.5 e 6.
3. Visualizar os dados
 - a. utilizando a função ***plot()*** de ***matplotlib***, construa os seguintes gráficos de dispersão:
 - verificar as áreas mais densas (com mais pontos)
 - relacionar a população com o preço mediano
 - b. calcule o coeficiente de correlação entre os atributos e verifique a correlação de cada atributo com o preço mediano das casas.
 - c. utilizando a função ***scatter_matrix()*** de ***pandas***, verifique graficamente a correlação entre os 5 atributos com maior correlação com o preço mediano das casas (incluindo o próprio preço)
 - d. Verifique em pormenor o gráfico de dispersão da correlação com o preço mediano. O que observa?
4. Limpar os dados
 - a. Verifique que atributos têm valores em falta e substitua-os pela mediana
 - b. Verifique os valores do atributo "ocean_proximity". Utilize a função ***OneHotEncoder()*** para transformá-lo num (conjunto de) atributo numérico. Porquê não faz sentido atribuir um valor numérico diferente a cada valor de "ocean_proximity"?
 - c. Uniformize os dados usando uma das funções ***StandardScaler()*** ou ***MinMaxScaler()***.
5. Treinar modelos
 - a. Utilizando validação cruzada com $k=10$, construa os seguintes modelos utilizando os hiper-parâmetros por omissão (para cada um, verifique quais os seus valores):
 - regressão linear com solução analítica (SVD): ***LinearRegression()***
 - descida do gradiente estocástica: ***SGDRegressor()***
 - regressão polinomial grau 2 com SVD: ***PolynomialFeatures()***

- regressão Ridge com solução analítica: `Ridge()`
 - regressão Ridge descida do gradiente estocástica: `SGDregressor()`
 - regressão Lasso: `Lasso()` ou `SGDregressor()`
- b. Observa situações de sub- e sobre-ajustamento nos modelos criados?
- c. Utilizando o algoritmo Elastic Net:
- com hiper-parâmetros por omissão, divida o conj de treino em validação e teste (80-20%) e verifique o erro em ambos os conjuntos ao longo do processo de aprendizagem através de um gráfico. Verifica sinais de sobre-ajustamento no modelo final? Em caso positivo, onde estaria o melhor modelo?
 - faça o fine-tuning usando grid search ou randomized search.