

# Redes Neurais e Aprendizagem Profunda

## Tensorflow playground



O TensorFlow Playground (<https://playground.tensorflow.org/>) é um simulador de rede neuronais desenvolvido pela equipa do TensorFlow. Pretende-se, com este exercício, treinar vários classificadores binários para ganhar alguma intuição sobre como as redes neuronais funcionam e o que faz cada hiperparâmetro.

1. Camadas e padrões.  
Treine a rede neuronal padrão. Observe como encontra rapidamente uma boa solução para a tarefa de classificação. O que distingue os padrões das duas camadas escondidas?
2. Funções de ativação.  
Substitua a função de ativação  $\tanh()$  pela função  $\text{ReLU}()$  e treine a rede novamente. O que observa?
3. Mínimos locais.  
Modifique a arquitetura da rede para ter apenas uma camada escondida com três neurónios. Treine várias vezes (para redefinir os pesos da rede, clique no botão Reset). O que observa no que diz respeito ao tempo de treino? Encontra sempre a solução ótima?
4. Rede demasiado pequena.  
Remova um neurónio para manter apenas dois. O que observa?
5. Rede demasiado grande.  
Aumente o número de neurónios para oito e treine a rede várias vezes. O que observa agora?
6. O risco do desaparecimento dos gradientes em redes profundas.  
Selecione o conjunto de dados espiral e altere a arquitetura da rede para ter quatro camadas ocultas com oito neurónios cada. O que observa no que diz respeito ao tempo de treino? E aos padrões aprendidos em cada camada?
7. Altere outros parâmetros para uma ideia do que permitem fazer construindo uma compreensão intuitiva sobre redes neuronais.

1. Os neurónios na primeira camada escondida aprendem padrões simples, enquanto os neurónios na segunda camada aprendem a combinar os padrões simples da primeira camada em padrões mais complexos. Em geral, quanto mais camadas houver, mais complexos podem ser os padrões.
2. Observe que encontra uma solução ainda mais rápido mas, desta vez, com limites lineares. Isso deve-se à forma da função ReLU.
3. Observe que o tempo de treino varia muito e que, às vezes, até pára num mínimo local.
4. Observe que a rede é incapaz de encontrar uma boa solução, mesmo após várias tentativas. O modelo tem muito poucos parâmetros e sistematicamente subajusta.
5. Observe que agora é consistentemente rápido e nunca fica preso. Isso destaca uma característica importante: redes neuronais grandes quase nunca ficam presas em mínimos locais e, quando ficam, esses ótimos locais são quase tão bons quanto os ótimos globais. No entanto, ainda podem ficar presos em longos planaltos por muito tempo.
6. Note que o treino leva muito mais tempo e muitas vezes fica preso em planaltos por longos períodos de tempo.  
Observe também que os neurónios nas camadas mais altas (à direita) tendem a evoluir mais rápido do que os neurónios nas camadas mais baixas (à esquerda). Este problema, chamado de problema do desaparecimento dos gradientes (*vanishing gradients*), pode ser aliviado com uma melhor inicialização de peso e outras técnicas, melhores otimizadores, ou normalização em batch (apresentadas no futuro)