
Redes Neurais e Aprendizagem Profunda

— Aprendizagem supervisionada —

Sumário

- Aprendizagem supervisionada
- Classificação
- Um primeiro classificador

Aprendizagem Supervisionada

Aprendizagem supervisionada

- Aprendizagem supervisionada
 - Prever um resultado dada uma entrada
 - Existem exemplos de pares entrada/resultado
- Processo
 - Construir um modelo de AA a partir dos pares entrada/resultado (dados de treino)
- Objetivo
 - Fazer previsões precisas sobre dados novos, nunca antes vistos
- Requer esforço para construir o conj de treino

Termos Gerais (1)

- Objeto de interesse
 - Instância, x
- Espaço de instâncias
 - Conjunto de todas as instâncias possíveis, X
- Espaço de etiquetas
 - Conjunto de etiquetas utilizadas para etiquetar as instâncias, L
- Exemplo
 - Par constituído por uma instância e a etiqueta correspondente, $\{ x, l(x) \}$

Termos Gerais (2)

- Espaço de entrada
 - Espaço de instâncias
- Espaço vectorial
 - Tipo de espaço de entrada
 - Utiliza uma número fixo de atributos, d , para descrever uma instância
 - Cada instância é um vetor de valores de atributos
- Espaço de saída
 - Classificação: conjunto de classes
 - Regressão: conjunto de números reais

Termos Gerais (3)

- Modelo
 - Mapeamento entre o espaço de entrada e o espaço de saída
- Dados de treino
 - Conjunto de instâncias etiquetadas (exemplos), T_r , utilizado para **construir** o modelo
- Dados de teste
 - Conjunto de instâncias etiquetadas (exemplos), T_e , utilizado para **avaliar** o modelo
 - A avaliação é necessária porque podemos ter dados com ruído

Classificação e Regressão

- Classificação

- Prever uma etiqueta (entre uma lista pré-definida de possibilidades)
- Exemplos
 - Mensagens spam, língua de um texto

- Regressão

- Prever um valor contínuo
- Exemplos
 - Rendimento anual de uma pessoa (dada a educação, idade, onde vive, ...)
 - produção de uma cultura (dada produção anterior, tempo, nº empregados, ...)

Classificação


Classificação

- Objetivo
 - Encontrar um mapeamento entre o espaço de entrada X e o espaço de etiquetas C
 - C é um conjunto finito e usualmente com **poucas etiquetas**
- Classificador
 - Modelo de classificação
- Exemplo
 - Par $(x, c(x))$, sendo x uma instância e $c(x)$ a verdadeira classe da instância x
- Construir um classificador
 - Construir uma função $\hat{c}()$ tal que iguale $c()$ o mais possível
 - Não apenas no conjunto de treino mas, idealmente, em todo o espaço de instâncias X

Problemas de classificação

- Binário
 - Duas classes, normalmente positiva e negativa
 - Também conhecido como **aprendizagem de conceito** (se a classe positiva for um conceito)
- Multi-classe
 - K classes (mais de 2)
 - Cada exemplo pertence a uma única classe
- Multi-etiqueta
 - K classes
 - Cada exemplo pode pertencer a mais que uma classe

Construção de um classificador



Avaliação do desempenho do classificador

- Matriz de confusão
 - Tabela que **sumariza** o desempenho do classificador
 - Também conhecida como **tabela de contingência**
- Construção da matriz de confusão
 - As linhas referem a classe **real**
 - As colunas referem a classe **prevista**
 - As células contêm a contagem das instâncias (do conjunto de treino/validação)

Matriz de confusão

- Desempenho
 - Diagonal descendente indica as previsões corretas
 - Diagonal ascendente indica erros de predição

- Exemplo

- 50 instâncias positivas
 - 30 classificadas corretamente
 - 20 mal classificadas
- 50 instâncias negativas
 - 40 classificadas corretamente
 - 10 mal classificadas

	<i>Prevista +</i>	<i>Prevista -</i>	
<i>Real +</i>	30	20	50
<i>Real -</i>	10	40	50
	40	60	100

Mais terminologia

- Marginais
 - Última linha e coluna
- TP
 - Verdadeiros positivos
- TN
 - Verdadeiros negativos
- FP
 - Falsos positivos
- FN
 - Falsos negativos

	<i>Predicted +</i>	<i>Predicted -</i>	
<i>Actual +</i>	TP	FN	$Pos=TP+FN$
<i>Actual -</i>	FP	TN	$Neg=TP+FN$
<i>Marginais de predição</i>			<i># instâncias</i>

Indicadores de desempenho

- Calculados sobre a matriz de confusão
- Existe uma grande variedade de indicadores
 - Exatidão (accuracy)
 - Taxa de erro (error rate)
 - Taxa de verdadeiros positivos, Taxa de verdadeiros negativos
 - Pode ser visto como uma exatidão por classe
 - Taxa de falsos negativos, Taxa de falsos positivos
 - Pode ser visto como uma taxa de erro por classe
 - Precisão (precision)

Uma primeira aplicação

Espécies Iris

- Problema
 - Distinguir a espécie de flores iris
- Espécies
 - Setosa, Versicolor, Virginica
- Caracterização da flor
 - Comprimento e largura da pétala
 - Comprimento e largura da sépala



<https://archive.ics.uci.edu/ml/datasets/Iris>

Enquadramento

- Objetivo
 - Criar um modelo de aprendizagem automática
 - Aprende a espécie a partir das medidas de flores cuja espécie é conhecida
 - É capaz de prever a espécie de uma nova flor
- Tarefa
 - **Aprendizagem supervisionada**
 - A espécie de cada flor é conhecida
 - Problema de **classificação** com 3 classes
 - Cada flor é caracterizada por 4 **atributos**
 - Cada flor é de uma espécie
 - Cada espécie é uma **etiqueta**

Conjunto de dados

Caracterização do conjunto de dados

- Instâncias: 150
- Atributos: 4 (numéricos)
 - Sepal length
 - Sepal width
 - Petal length
 - Petal width
- Classes: 3
 - Setosa
 - Versicolor
 - Virginica

```
4.4,3.0,1.3,0.2,Iris-setosa
5.1,3.4,1.5,0.2,Iris-setosa
5.0,3.5,1.3,0.3,Iris-setosa
4.5,2.3,1.3,0.3,Iris-setosa
4.4,3.2,1.3,0.2,Iris-setosa
5.0,3.5,1.6,0.6,Iris-setosa
5.1,3.8,1.9,0.4,Iris-setosa
4.8,3.0,1.4,0.3,Iris-setosa
5.1,3.8,1.6,0.2,Iris-setosa
4.6,3.2,1.4,0.2,Iris-setosa
5.3,3.7,1.5,0.2,Iris-setosa
5.0,3.3,1.4,0.2,Iris-setosa
7.0,3.2,4.7,1.4,Iris-versicolor
6.4,3.2,4.5,1.5,Iris-versicolor
6.9,3.1,4.9,1.5,Iris-versicolor
5.5,2.3,4.0,1.3,Iris-versicolor
6.5,2.8,4.6,1.5,Iris-versicolor
5.7,2.8,4.5,1.3,Iris-versicolor
6.3,3.3,4.7,1.6,Iris-versicolor
4.9,2.4,3.3,1.0,Iris-versicolor
6.6,2.9,4.6,1.3,Iris-versicolor
5.2,2.7,3.9,1.4,Iris-versicolor
5.0,2.0,3.5,1.0,Iris-versicolor
5.9,3.0,4.2,1.5,Iris-versicolor
6.0,2.2,4.0,1.0,Iris-versicolor
6.1,2.9,4.7,1.4,Iris-versicolor
5.6,2.9,3.6,1.3,Iris-versicolor
6.7,3.1,4.4,1.4,Iris-versicolor
5.6,3.0,4.5,1.5,Iris-versicolor
5.8,2.7,4.1,1.0,Iris-versicolor
6.2,2.2,4.5,1.5,Iris-versicolor
5.6,2.5,3.9,1.1,Iris-versicolor
```

Conjuntos de treino e teste

- É necessário avaliar o modelo antes de o utilizar
 - Verificar se de facto funciona e se podemos confiar nas suas predições
- A avaliação **não** pode ser feita sobre os dados usados na construção do modelo
 - O modelo pode apenas memorizar os dados
 - Não nos dá indicação se o modelo generaliza bem
 - É necessário avaliar o modelo sobre novos dados (não vistos antes)
- Solução
 - Dividir os dados em 2 sub-conjuntos
 - Conj. treino: utilizado para construir o modelo
 - Conj. teste: utilizado para avaliar o modelo

Divisão treino/teste

- Proporção
 - Conj. treino: 70% - 75%
 - Conj. teste: 30% - 25%
- Garantir distribuições semelhantes
 - “baralhar” antes da divisão
 - normalmente através da geração de n° aleatórios
- Replicar as experiências
 - garantir a mesma divisão através da definição da “semente” dos n° aleatórios


Inspeção dos dados

Inspeção dos dados

- Antes de criar um modelo é importante inspecionar os dados
 - Verificar se a tarefa é facilmente resolvida sem AA
 - Ver se os dados contêm a informação desejada
 - Encontrar anormalidades
 - inconsistências ou medições inesperadas
- Uma das melhores formas é **visualizar** os dados
 - Utilizar um **scatter plot**
 - Coloca um atributo em cada eixo
 - Marca um ponto no espaço para cada instância
 - Apenas é possível utilizar 2 (ou 3) atributos de cada vez

Pair plots

- Pair plot
 - scatter plot para todos os pares de atributos
- Não mostra a interação entre todos os atributos ao mesmo tempo
 - Alguns aspetos interessantes dos dados podem não ser revelados



Construção do modelo

Algoritmo

- Escolher um algoritmo de classificação (entre a grande variedade existente)
 - K-vizinhos-mais-próximos
- Algoritmo
 - Construção do modelo
 - Guardar o conj. de dados
 - Fazer uma previsão
 - Encontrar o ponto mais próximo do novo ponto
 - Etiquetar o novo ponto com a etiqueta do ponto de treino encontrado
 - K
 - Em vez de utilizar o vizinho mais próximo, considera K vizinhos
 - Faz a previsão usando, por exemplo, a maioria

Avaliação do modelo

Avaliação

- Utilizar o conj de teste
 - Para cada flor do conjunto, fazer a previsão e compará-la com a sua etiqueta (espécie)
- Analisar a matriz de confusão
 - As linhas correspondem à verdadeira classe
 - As colunas correspondem à classe prevista
 - Cada entrada tem a contagem de exemplos para essa combinação
- Calcular uma (ou mais) medidas de desempenho
 - Exatidão: fração de flores com previsão correta da espécie

Matriz de confusão

- Etiquetas

- setosa: 0 versicolor: 1 virginica: 2

- Etiquetas conj. de teste (38 exemplos)

- Verdadeira 2 1 0 2 0 2 0 1 1 1 2 1 1 1 1 0 1 1 0 0 2 1 0 0 2 0 0 1 1 0 2 1 0 2 2 1 0 **1**
- Prevista 2 1 0 2 0 2 0 1 1 1 2 1 1 1 1 0 1 1 0 0 2 1 0 0 2 0 0 1 1 0 2 1 0 2 2 1 0 **2**

- Matriz de confusão

	0	1	2	prevista
0	13	0	0	
1	0	15	1	
2	0	0	9	
real				

$$\text{Exatidão} = (13+15+9) / 38$$

Scikit-Learn

Código

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import confusion_matrix

iris_dataset = load_iris()

X_train, X_test, y_train, y_test = train_test_split(iris_dataset['data'], iris_dataset['target'],
random_state=0)

knn = KNeighborsClassifier( n_neighbors=1)
knn.fit(X_train, y_train)

pred_knn = knn.predict(X_test)

confusion = confusion_matrix(y_test, pred_knn)
print("Confusion matrix:\n{}".format(confusion))
print("Test set accuracy: {:.2f}".format(knn.score(X_test, y_test)))
```