
Redes Neurais e Aprendizagem Profunda

Generalização

Sumário

- Generalização
- Sobre- e sub-ajustamento
- Ruído
- Enviesamento e variância

Generalização

Generalização e complexidade

- Generalização
 - O modelo **generaliza** a partir do conj treino para o conj teste quando faz previsões exatas sobre dados novos
- Complexidade
 - Se o modelo for **muito complexo**, pode ser tão exato quanto quisermos sobre o conj de treino. Há memorização dos dados
 - Neste caso, normalmente o desempenho sobre o conj teste será fraco


Exemplo

- Tarefa
 - Prever se um cliente vai comprar um barco
- Modelo 1
 - **age>45 and (nr_children<3 or marital_status != divorced)**
 - exatidão=100%
 - Parece ser demasiado complexo!
- Modelo 2
 - **age>50**
 - Se explicar o comportamento de todos os clientes, seria preferível ao modelo 1
- Pretende-se encontrar o modelo mais simples que explique os dados!

Age	Number of cars owned	Owns house	Number of children	Marital status	Owns a dog	Bought a boat
66	1	yes	2	widowed	no	yes
52	2	yes	3	married	no	yes
22	0	no	0	married	yes	no
25	1	no	1	single	no	no
44	0	no	2	divorced	yes	no
39	1	yes	2	married	yes	no
26	1	no	2	single	no	no
40	3	yes	1	married	yes	no
53	2	yes	2	divorced	no	yes
64	2	yes	3	divorced	no	no
58	2	yes	2	married	yes	yes
33	1	no	1	single	no	no

Complexidade do modelo

- Quanto **mais complexo**, melhor será capaz de prever sobre o conj treino
- Se for demasiado complexo, começa a focar-se demasiado em cada exemplo do conj treino e **não generaliza** bem



Sobre-ajustamento e sub-ajustamento

- Sobre-ajustamento
 - *Overfitting*
- O que é?
 - Construção de um modelo **demasiado complexo** para a quantidade de informação disponível
- Quando acontece?
 - Quando o modelo é ajustado às particularidades do conj treino
- Característica
 - Obtém-se um modelo que funciona bem para o conj treino, mas não consegue generalizar para novos dados
- Sub-ajustamento
 - *Underfitting*
- O que é?
 - Construção de um modelo **demasiado simples**
- Quando acontece?
 - Quando não consegue capturar todos os aspetos e variabilidade dos dados
- Característica
 - Obtém-se um modelo que não tem um bom desempenho nem no conj de treino

Complexidade e tamanho do conj de dados

- Complexidade e sobre-ajustamento
 - Quanto **maior a variedade** de exemplos no conj de dados, mais complexo pode ser o modelo sem sobre-ajustamento
- Variedade e tamanho do conj dados
 - Normalmente, a existência de mais dados corresponde a uma maior variedade
 - Mas... duplicar ou colecionar dados muito semelhantes não ajuda...
- Exemplo
 - Se a regra do Modelo 1 (slide 5, *age>45 and (nr_children<3 or marital_status != divorced)*) fosse aplicável a 10000 exemplos e não apenas a 12, mais facilmente diríamos que esta era uma **boa regra!**

Sobre-ajustamento


- Para evitar
 - o número de parâmetros estimados a partir dos dados deve ser **consideravelmente inferior** ao número de instâncias
- Exemplo
 - Polinómio
 - # parâmetros = grau do polinómio + 1
 - $a x^2 + b x + c$
 - grau 2 -> 3 parâmetros: a, b, c

Ruído, enviesamento e variância

Dados ruidosos

- Ruído
 - Ruído na etiqueta
 - Quando se observa uma **etiqueta corrompida** para uma instância, l' em vez de $l=l(x)$
 - Ruído na instância
 - Quando se observa uma **instância corrompida**, x' em vez de x
- Consequência
 - O algoritmo não deve tentar fazer corresponder exatamente os dados de treino, já que pode conduzir a **sobre-ajustamento do ruído**

Enviesamento e variância



Dilema enviesamento-variância

- Modelos de baixa complexidade
 - Sofrem menos da variabilidade com as variações aleatórias nos dados de treino
 - Podem introduzir um **enviesamento sistemático**
- Modelos de grande complexidade
 - Eliminam o enviesamento
 - Podem sofrer de erros não sistemáticos devido à variância